

Área académica:
Ingeniería

Asignatura:
Arquitectura de Grandes Volúmenes de Datos

Título:
Proyecto Integrador: Monitor Sísmico Global
Arquitectura de Big Data de extremo a extremo con datos reales del USGS

Maestro:
Lorenzo Antonio Martinez Lebron

Estudiantes:
Ezequiel Jiménez, ID: 1116656
Adonis de los Angeles, ID: 1128136
Grupo B

Fecha:
Sábado 17 de octubre del 2026

Indice

1. Resumen ejecutivo *4*

2. Introducción *4*

2.1 Contexto y problema 4

2.2 Objetivos 4

3. Visión general de la solución *5*

3.1 Arquitectura 5

3.2 Principios de diseño 5

3.3 Tecnologías y por qué se eligieron 6

3.4 Cómo viaja un dato 6

4. Los datos *6*

4.1 Fuentes 6

4.2 Modelo de datos 7

4.3 Volumen 7

5. Capa 1: ingesta con Apache NiFi *7*

5.1 Estrategia 7

5.2 Pipeline en vivo 7

5.3 Calidad en la entrada 8

5.4 Control de flujo 8

5.5 Carga histórica 9

5.6 Trazabilidad y observabilidad 9

6. Capa 2: procesamiento con PySpark *10*

6.1 Rol 10

6.2 Pasos del procesamiento 10

6.3 Decisiones de diseño relevantes 10

6.4 Resultados 11

7. Capa 3: almacenamiento con PostgreSQL *11*

7.1 Particionamiento 11

7.2 Carga idempotente 11

7.3 Respaldo y restauración 12

7.4 Tablas operacionales 12

8. Calidad de los datos *12*

9. Capa 4: análisis y consultas *13*

9.1 Enfoque 13

9.2 Las cinco consultas **13**
9.3 Rendimiento **13**
10. Capa 5: visualización con Grafana ***14***
10.1 Grafana como código **14**
10.2 Dashboard de negocio **14**
10.3 Dashboard operacional **14**
10.4 Una lección de diseño **15**
11. Operación y reproducibilidad ***15***
12. Conclusiones ***16***
Anexo A. Glosario ***16***

1. Resumen ejecutivo

Este informe describe el diseño, la construcción y los resultados del **Monitor Sísmico Global**, un sistema de big data de extremo a extremo que recoge, depura, almacena, analiza y visualiza los terremotos registrados por el Servicio Geológico de los Estados Unidos (USGS). Es el proyecto integrador de la asignatura Arquitectura de Grandes Volúmenes de Datos y cubre las cinco capas exigidas: ingesta, procesamiento, almacenamiento, análisis y visualización.

El sistema trabaja con **datos reales y abiertos**: un flujo en vivo que consulta la API del USGS cada cinco minutos y una carga histórica de cinco años organizada en 61 ventanas mensuales. Ambas fuentes se unifican en una base de datos de **81 044 sismos de magnitud 4.0 o mayor**, entre octubre de 2021 y octubre de 2026, descritos con **46 columnas**: ubicación, magnitud, calidad de la medición, impacto humano y variables derivadas como la energía liberada o la probabilidad de que un evento sea una réplica.

Tres decisiones definieron el proyecto. La primera fue **tratar la calidad de los datos como una responsabilidad de cada capa**, no como una limpieza final: se validan los registros al entrar, se depuran al procesarlos y se auditan al consultarlos. La segunda fue **construir todo como código reproducible**: los flujos de ingesta, la base de datos y los dashboards se crean con scripts, de modo que cualquier persona puede levantar el sistema completo con unos pocos comandos. La tercera fue **medir en lugar de afirmar**: las mejoras de rendimiento y las correcciones de calidad se comprobaron con evidencia.

Los resultados principales son los siguientes:

- Dos pipelines de NiFi con validación, deduplicación, control de flujo y trazabilidad, sin ningún registro rechazado en la carga final.
- Un proceso de Spark de unos 40 segundos que deja la base lista, con 12 zonas sísmicas calculadas mediante aprendizaje automático.
- Una base PostgreSQL particionada por mes, cuya carga es idempotente y cuyo respaldo se restaura en menos de un minuto.
- Cinco consultas analíticas avanzadas y un benchmark reproducible: la poda de particiones lee **98.6 % menos datos** que la misma consulta sin poda.
- Dos dashboards de Grafana, uno de negocio (9 paneles) y uno operacional (11 paneles), que se instalan solos al levantar el sistema.

2. Introducción

2.1 Contexto y problema

Cada día ocurren decenas de terremotos de magnitud moderada en el mundo. El USGS los publica de forma abierta, pero la información llega en formatos distintos, con campos que cambian según la fuente y con revisiones posteriores que corrigen datos ya publicados. Quien quiere analizarlos enfrenta tres problemas: integrar fuentes en tiempo real e históricas, confiar en la calidad de lo que recibe y convertir millones de datos en respuestas útiles.

Un catálogo sísmico es además un buen caso de estudio para big data porque reúne las dificultades típicas de este tipo de sistemas: datos que se actualizan constantemente, duplicados entre fuentes, valores que se revisan con el tiempo, campos dispersos y la necesidad de consultar por rangos de tiempo y por zonas geográficas.

2.2 Objetivos

El **objetivo general** es construir una arquitectura de datos completa y reproducible que convierta los registros sísmicos del USGS en información analítica y visual. Los objetivos específicos son:

- Ingerir al menos dos fuentes distintas con validación, manejo de errores y control de flujo.
- Procesar los datos para limpiarlos, enriquecerlos y agruparlos, aplicando aprendizaje automático básico.
- Almacenarlos en un modelo particionado, con carga repetible y estrategia de respaldo.
- Responder preguntas de negocio con al menos cinco consultas y medir su rendimiento.
- Presentar los resultados en un dashboard de negocio y otro operacional, con filtros interactivos.

3. Visión general de la solución

3.1 Arquitectura

La Figura 1 resume el recorrido de los datos. Las tres fuentes del USGS entran por Apache NiFi, que las valida y deja los archivos resultantes en una zona intermedia llamada *raw*. PySpark lee esa zona, depura y enriquece los datos y los carga en PostgreSQL. Desde la base, las consultas SQL y Grafana producen el análisis y las visualizaciones.

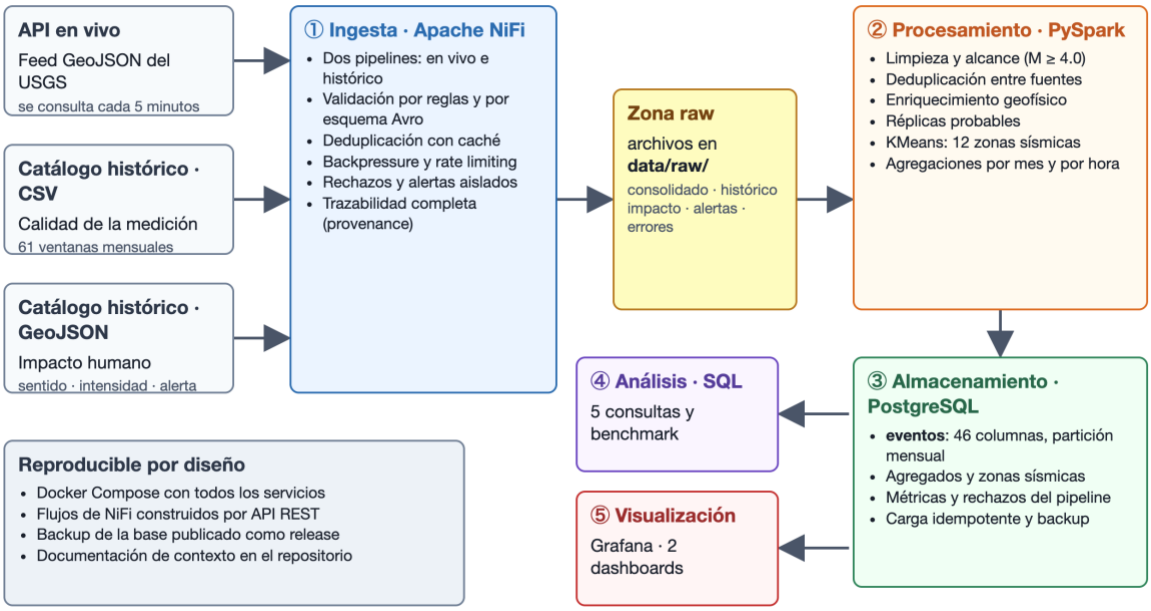


Figura 1. Arquitectura general del Monitor Sísmico Global.

3.2 Principios de diseño

Seis ideas guiaron todas las decisiones:

- **Desacople por archivos.** Las capas no se llaman entre sí: NiFi escribe archivos y Spark los lee. Cada capa se puede probar, repetir o reemplazar sin tocar las demás.
- **Idempotencia.** Ejecutar el proceso dos veces produce el mismo resultado. No hay que preocuparse por duplicar datos al reintentar.
- **Calidad en cada capa.** Se valida al ingresar, se depura al procesar y se documentan las reglas de uso para quien consulta.
- **Todo como código.** Flujos, esquemas, dashboards y servicios se definen en archivos versionados y se despliegan con scripts.

- **Simplicidad deliberada.** Se evitaron componentes que la rúbrica no exige, como Kafka o HDFS, porque agregarían complejidad sin aportar valor a este volumen de datos.
- **Evidencia medible.** Cada mejora se acompaña de una medición o una comprobación verificable.

3.3 Tecnologías y por qué se eligieron

Capa	Tecnología	Por qué
Ingesta	Apache NiFi 2.7.2	Permite diseñar flujos visuales con validación, enrutamiento de errores, control de flujo y trazabilidad ya incorporados
Procesamiento	PySpark 3.5	Procesa lotes grandes, incluye aprendizaje automático (KMeans) y funciones de ventana
Almacenamiento	PostgreSQL 16	Ofrece particionamiento declarativo, índices y SQL analítico completo
Análisis	SQL avanzado	Funciones de ventana, estadística y geodesia directamente donde viven los datos
Visualización	Grafana 13	Se aprovisiona por archivos, soporta variables, mapas y actualización automática
Despliegue	Docker Compose	Un solo archivo levanta todos los servicios en cualquier equipo

3.4 Cómo viaja un dato

Un caso real ilustra el recorrido completo: el terremoto de Kahramanmaraş, en Turquía, de magnitud 7.8, ocurrido el 6 de febrero de 2023.

1. **Ingesta.** El flujo histórico pide la ventana de febrero de 2023 dos veces: una en CSV, que trae la calidad de la medición, y otra en GeoJSON, que trae el impacto humano. Un limitador de ritmo espacia las consultas para no saturar al USGS.
2. **Procesamiento.** Spark une ambos archivos por el identificador del evento, comprueba que cumple las reglas de calidad y el alcance, y calcula la energía liberada: unos 31.6 petajoules. Como el USGS lo titula "Kahramanmaras Earthquake Sequence", sin indicar el país, la normalización de regiones lo asigna a Turquía.
3. **Almacenamiento.** El evento se guarda en la partición de febrero de 2023. Su profundidad figura como *fija*: el USGS no la pudo medir y usó un valor por defecto, por lo que las consultas de profundidad lo excluyen.
4. **Análisis y visualización.** Entra en el balance de energía de Turquía, en la detección de anomalías mensuales y aparece como un punto grande en el mapa de Grafana, con alerta PAGER roja.

4. Los datos

4.1 Fuentes

Fuente	Tipo	Qué aporta	Frecuencia
Feed GeoJSON del USGS	API REST en tiempo casi real	Sismos recientes, con sus campos de impacto	Cada 5 minutos
Catálogo FDSN en CSV	Carga por lotes	Calidad de la medición: estaciones, errores, red sismográfica	61 ventanas mensuales
Catálogo FDSN en GeoJSON	Carga por lotes	Impacto humano: personas que lo sintieron, intensidad, alerta PAGER, tsunami	61 ventanas mensuales

Ningún formato del USGS trae todos los campos a la vez. Por eso cada ventana histórica se solicita dos veces y se unifica después por el identificador del evento. Es una decisión de diseño que se aprecia en la Figura 4.

4.2 Modelo de datos

La tabla principal, `sismos.eventos`, reúne **46 columnas** agrupadas en cinco bloques:

Bloque	Qué contiene	Ejemplos
Descripción del evento	Cuándo, dónde y qué tan fuerte	fecha, magnitud, profundidad, latitud, longitud, región
Calidad de la medición	Qué tan confiable es el dato	estaciones, brecha azimutal, errores de ubicación y magnitud, red sismográfica
Impacto humano	Efecto sobre las personas	reportes de sentido, intensidades, alerta PAGER, tsunami, significancia
Variables derivadas	Calculadas por Spark	energía, calendario, localidad de referencia, réplica probable
Linaje y modelo	Trazabilidad	fuente, zona sísmica (clúster), fecha de ingesta

Además existen tablas de apoyo: agregados por región y mes, agregados por hora, descripción de las 12 zonas sísmicas, métricas del pipeline y registro de rechazos.

4.3 Volumen

Indicador	Valor
Sismos almacenados	81 044
Período	1 de octubre de 2021 al 17 de octubre de 2026
Regiones distintas	376
Redes sismográficas	15
Tamaño del respaldo comprimido	6.2 MB

5. Capa 1: ingesta con Apache NiFi

5.1 Estrategia

La ingesta resuelve tres problemas: obtener datos de dos tipos de fuente, impedir que entren registros defectuosos y hacerlo sin sobrecargar ni al sistema ni a la API del USGS. Se construyeron dos pipelines complementarios, uno para el flujo en vivo y otro para la carga histórica. Ambos se crean con scripts que usan la API de NiFi, lo que permite reconstruirlos desde cero en segundos.

5.2 Pipeline en vivo

El pipeline en vivo se organiza en cinco grupos encadenados, que se muestran en la Figura 2. Cada grupo tiene una responsabilidad clara.

Grupo	Responsabilidad
1. Ingesta	Consulta la API cada 5 minutos, etiqueta el origen y separa cada sismo en un registro propio
2. Validación	Extrae los campos clave, aplica 6 reglas de calidad y descarta los duplicados
3. Procesamiento	Clasifica por magnitud, agrega metadatos y normaliza la estructura
4. Salida	Consolida los registros en archivos CSV por categoría y genera alertas

Grupo	Responsabilidad
5. Manejo de errores	Registra y archiva todo lo rechazado, por etapa y por motivo

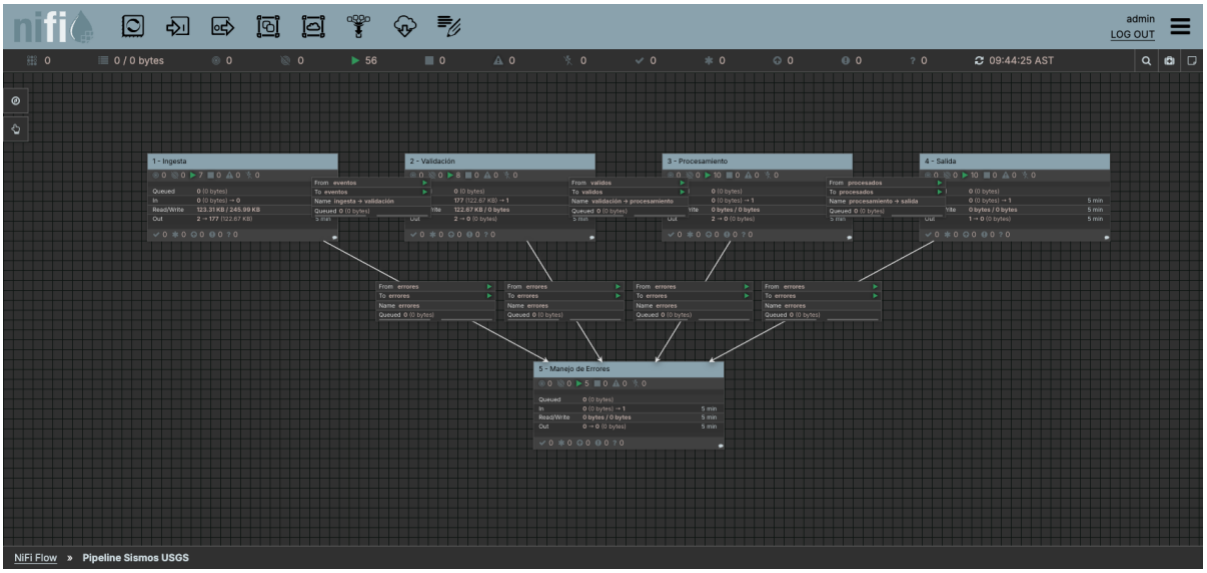


Figura 2. Pipeline en vivo en NiFi: los cinco grupos y el flujo hacia el manejo de errores.

5.3 Calidad en la entrada

Un registro solo avanza si supera seis reglas: tiene identificador, la magnitud es numérica y está en un rango físico razonable, el tiempo es válido, las coordenadas son números y el tipo de evento está presente. Lo que falla no se pierde ni se ignora: se desvía al grupo de errores, donde se guarda con el motivo exacto del rechazo.

La **deduplicación** usa una caché en memoria con una clave formada por el identificador del evento y su fecha de actualización. Como la API devuelve las últimas 24 horas en cada consulta, sin esta defensa el mismo sismo entraría decenas de veces. En una lectura típica de cinco minutos, de 261 eventos recibidos 260 eran repetidos y solo 1 continuó su camino.

5.4 Control de flujo

Dos mecanismos protegen al sistema, y ambos son visibles en la Figura 3:

- **Backpressure.** Cada conexión entre grupos tiene un límite de 10 000 objetos o 1 GB. Si un grupo se atrasa, NiFi detiene automáticamente al anterior en lugar de acumular datos sin control.
- **Rate limiting.** En la carga histórica, un limitador deja pasar una sola ventana cada cinco segundos. Así se respetan los límites de la API pública del USGS.

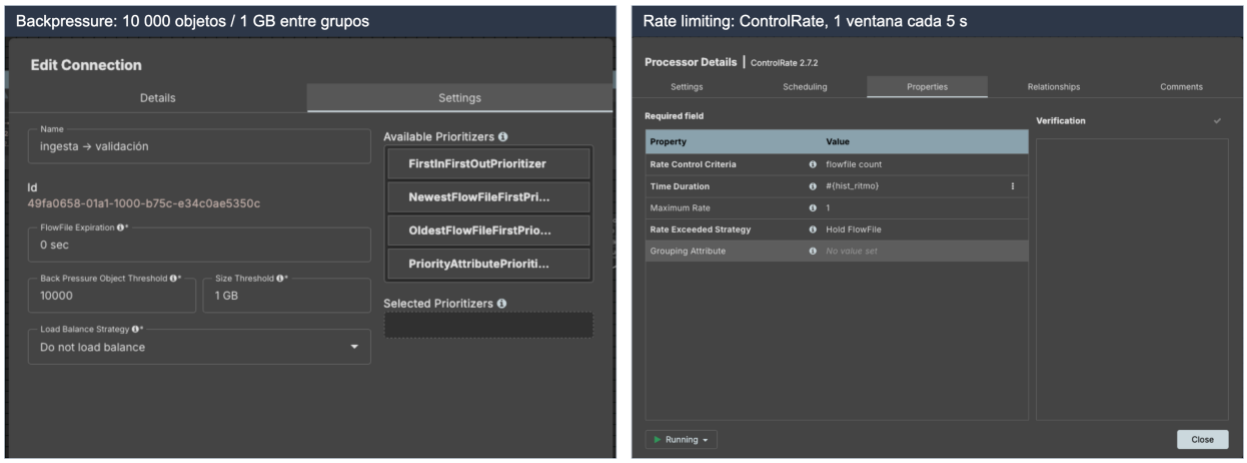


Figura 3. Backpressure entre grupos (izquierda) y limitación de ritmo en la carga histórica (derecha).

5.5 Carga histórica

El segundo pipeline recorre 61 ventanas mensuales, desde octubre de 2021 hasta hoy, y las divide en dos ramas paralelas, como muestra la Figura 4. La rama A descarga el CSV y lo valida contra un esquema formal que exige los campos obligatorios y comprueba los tipos de datos. La rama B descarga el GeoJSON, lo aplana a una tabla y lo guarda como CSV.

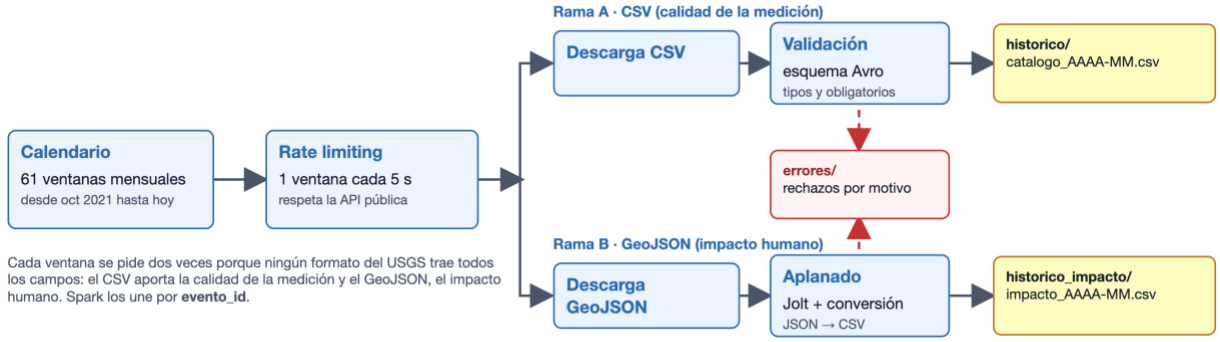


Figura 4. Carga histórica: calendario, limitación de ritmo y las dos ramas de descarga.

Los archivos se nombran por mes (por ejemplo, `catalogo_2026-10.csv`). De esta forma, refrescar una ventana sobrescribe el archivo anterior en lugar de acumular copias solapadas.

5.6 Trazabilidad y observabilidad

NiFi registra el recorrido de cada dato. La Figura 5 muestra el linaje de un evento que activó una alerta: desde que se separó del lote hasta que se escribió en disco, pasando por la clasificación, el enriquecimiento y la conversión de formato. Esta trazabilidad permite responder en segundos de dónde vino un registro y qué le ocurrió.

Además, un script lee periódicamente las estadísticas de NiFi y las guarda en la base de datos, alimentando el dashboard operacional.

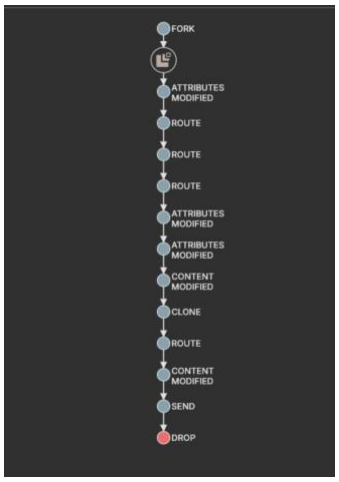


Figura 5. Linaje de un FlowFile, de su separación (FORK) a su escritura en disco (SEND).

6. Capa 2: procesamiento con PySpark

6.1 Rol

Spark toma los archivos de la zona raw y los convierte en información lista para consultar. Se ejecuta en lote, en unos 40 segundos, y es repetible: puede correr las veces que haga falta sin alterar el resultado.

6.2 Pasos del procesamiento

Paso	Qué hace	Por qué
Unión	Combina el feed en vivo, el CSV histórico y los datos de impacto por identificador	Cada fuente aporta una parte del cuadro completo
Limpieza	Normaliza texto y valida identificador, fecha, magnitud y coordenadas	Evita que datos inválidos lleguen a la base
Alcance	Conserva solo magnitudes de 4.0 o más	El feed trae magnitudes menores que el histórico no tiene; mezclarlas sesgaría las comparaciones
Deduplicación	Deja un registro por evento: gana el revisado, luego el histórico, luego el más reciente	El mismo sismo llega por varias vías
Enriquecimiento	Región, categorías, calendario, energía, localidad de referencia	Convierte datos crudos en variables analizables
Réplicas	Marca eventos que ocurren cerca y poco después de uno mucho mayor	Permite separar la actividad base de las secuencias
Agrupación	KMeans con 12 zonas sísmicas	Crea una división geográfica propia de los datos
Agregación	Resúmenes por región y mes, y por hora	Acelera las consultas más frecuentes

6.3 Decisiones de diseño relevantes

- **Región normalizada.** El USGS describe el lugar con texto libre, como "South of the Fiji Islands" o "Fiji region". Se aplicaron reglas para reducirlos a una sola entidad. El resultado fue pasar de 468 etiquetas a 376 regiones, y que Fiji dejara de aparecer repartida en tres nombres.
- **Profundidad fija.** El 41.3 % de los eventos tiene exactamente 10 km de profundidad, un valor por defecto del USGS cuando no puede medirla. En lugar de eliminar esos datos, se marcaron con una columna booleana: así se pueden excluir de los análisis de profundidad sin perder el resto de su información.

- **Energía liberada.** Se calcula con la relación de Gutenberg-Richter, donde cada punto de magnitud multiplica la energía por unas 32 veces. Es la métrica que permite comparar regiones por lo que realmente liberan, no solo por cuántos sismos tienen.
- **Réplica probable.** Se considera réplica a un evento ocurrido en las 72 horas posteriores a uno principal de magnitud 5.5 o más y al menos 0.5 mayor, dentro de la misma celda de 3 por 3 grados. Es una heurística explicable, no un modelo sismológico; así se documenta.
- **KMeans esférico.** Las coordenadas se transforman a un sistema tridimensional antes de agrupar. Así las zonas del Pacífico, que cruzan la línea de cambio de fecha en ±180°, no se parten artificialmente en dos.

6.4 Resultados

En la carga final, Spark leyó 81 516 registros, descartó 396 por quedar fuera del alcance (magnitud menor a 4.0), resolvió 76 duplicados entre fuentes, no encontró ningún registro inválido y dejó 81 044 eventos únicos.

7. Capa 3: almacenamiento con PostgreSQL

7.1 Particionamiento

La tabla de eventos se divide en **una partición por mes** (84 meses, de 2021 a 2027, más una partición de respaldo), para un total de 85. Casi todas las preguntas sobre sismos incluyen un rango de fechas, de modo que PostgreSQL puede ignorar por completo los meses que no interesan. El efecto se mide en la sección 9.3: la misma consulta lee un 98.6 % menos de datos cuando aprovecha las particiones.

Se agregaron además índices sobre la región, la magnitud y la zona sísmica, que aceleran las consultas más selectivas.

7.2 Carga idempotente

Cargar datos nuevos sobre una tabla existente es delicado. Un caso real lo demostró: el USGS corrige a veces la hora de un sismo por milisegundos. Como la clave de la tabla incluye la fecha, la versión corregida se insertó como si fuera un segundo evento, y la base llegó a tener 281 sismos duplicados. Además, 5 eventos revisados a una magnitud menor a 4.0 conservaban su valor antiguo.

La solución, que se muestra en la Figura 6, es una **carga en tres pasos dentro de una sola transacción**: se eliminan las versiones obsoletas de cada evento, se actualizan o insertan solo las filas que realmente cambiaron y se retiran los eventos que el catálogo ya no devuelve, únicamente en los meses cubiertos por esa corrida. Si algo falla, no queda nada a medias.

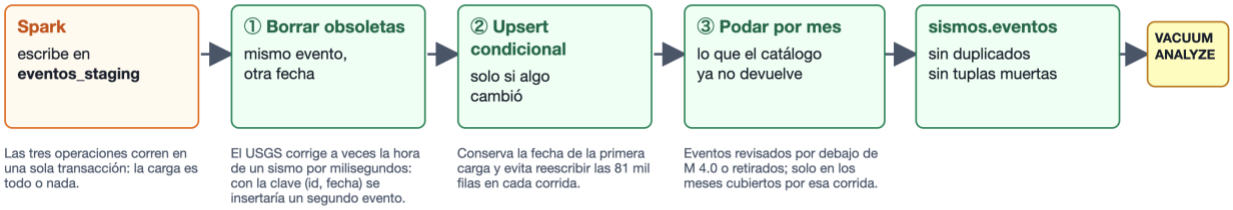


Figura 6. Carga idempotente a PostgreSQL: tres pasos en una transacción.

El segundo paso evita un problema silencioso: reescribir las 81 mil filas en cada corrida llenaba la tabla de versiones muertas y duplicaba el volumen leído por las consultas. Al reescribir solo lo que cambia y ejecutar una limpieza al terminar, las lecturas se mantienen estables.

7.3 Respaldo y restauración

El respaldo se genera con una sola orden, se comprime a unos 6 MB y se publica como *release* del repositorio. Para recuperar el sistema basta con levantar la base vacía y restaurar ese archivo, un proceso de menos de un minuto que se verificó sobre una base nueva: quedaron las 81 044 filas, las 46 columnas y las 85 particiones.

7.4 Tablas operacionales

Dos tablas sirven al monitoreo. Una guarda las métricas de cada ejecución de NiFi y de Spark (registros leídos, correctos, duplicados y con error, latencia y duración). La otra guarda los rechazos con su motivo y la cantidad de eventos que representa cada fila.

8. Calidad de los datos

Gran parte del trabajo consistió en descubrir qué estaba mal en los datos y decidir cómo tratarlo. La tabla resume los hallazgos principales.

#	Hallazgo	Decisión
1	El histórico no incluía el mes en curso, lo que creaba un hueco y un pico falso en las series diarias	Ventana parcial hasta la fecha actual
2	El feed trae todas las magnitudes y el histórico solo desde 4.0, por lo que no eran comparables	Alcance fijo de magnitud 4.0 o más
3	La región aparecía fragmentada en varios nombres y algunos sismos famosos no tenían país	Normalización por reglas; 468 pasaron a 376 regiones
4	El 41.3 % de las profundidades eran el valor por defecto de 10 km	Columna que lo marca, sin borrar el dato
5	El CSV no incluye el impacto humano	Segunda consulta en GeoJSON, unida por identificador
6	Cada carga reescribía todas las filas e inflaba la tabla	Actualización condicional y limpieza posterior
7	Las correcciones del USGS dejaron 281 duplicados y 5 eventos obsoletos	Carga en tres pasos, descrita en la sección 7.2
8	Los indicadores operacionales sumaban corridas completas y mostraban 564 742 registros	Mostrar la última lectura por componente

Los hallazgos 7 y 8 aparecieron al **integrar las dos mitades del proyecto**: la capa de visualización mostró una cifra imposible y su revisión llevó a corregir la carga. Es un recordatorio de que unir las partes y verificar de extremo a extremo no es un trámite, sino una etapa de calidad.

Para que el análisis no saque conclusiones falsas, se documentaron reglas de uso: filtrar solo terremotos naturales, excluir las profundidades fijas en cualquier estudio de profundidad, comparar únicamente años completos (2022 a 2025) y analizar los campos de impacto humano solo sobre los registros que tienen valor, porque son dispersos por naturaleza (por ejemplo, la alerta PAGER existe en el 4.9 % de los eventos).

9. Capa 4: análisis y consultas

9.1 Enfoque

El análisis se apoya en cinco invariantes que protegen la validez de cada resultado: considerar solo terremotos, excluir profundidades fijas cuando se estudia el interior de la Tierra, limitar las comparaciones a los cuatro años completos, filtrar siempre por rango de fechas para aprovechar las particiones y no consultar nunca la tabla temporal de carga.

9.2 Las cinco consultas

Consulta	Pregunta que responde	Qué se encontró
1. Gutenberg-Richter	¿Qué proporción de sismos pequeños y grandes tiene cada región y cuánta energía libera?	Rusia concentra el 67.8 % de la energía analizada (1 062 petajoules) por un único evento, el M8.8 de Kamchatka de 2025. Turquía muestra un parámetro b de 0.83, indicio de mayor estrés tectónico
2. Secuencias de réplicas	¿Con qué rapidez se suceden los sismos de una misma zona?	De 38 257 intervalos entre sismos consecutivos, el 22 % ocurre en menos de una hora, el 78 % en menos de 12 horas y el 97 % en menos de 48
3. Estratos de profundidad	¿Cómo cambian los sismos y el riesgo de tsunami con la profundidad?	La tasa de tsunami es de 2.8 % en los primeros 35 km y baja a 0.2 %–0.3 % por debajo de 300 km
4. Anomalías temporales	¿Cuándo hubo meses de actividad excepcional en una región?	Detectó las secuencias de Grecia (febrero de 2025), Turquía (febrero de 2023), Taiwán (abril de 2024) y Filipinas (diciembre de 2023), con desviaciones de más de 6 sigmas. La conciliación contra la tabla agregada dio cero diferencias
5. Zonas sísmicas y amenaza	¿Qué tan compactas son las 12 zonas y cuáles son más críticas?	Las tres zonas de mayor amenaza son las islas Aleutianas y Alaska, Tonga y Fiji, y Filipinas. El radio medio de una zona es de 1 100 a 1 500 km

9.3 Rendimiento

Un benchmark automatizado mide el efecto del particionamiento y de los índices. Cada escenario se ejecuta diez veces después de un calentamiento y se registran la mediana, el percentil 95 y los bloques de disco leídos. La Figura 7 compara cada consulta con su equivalente sin la optimización.

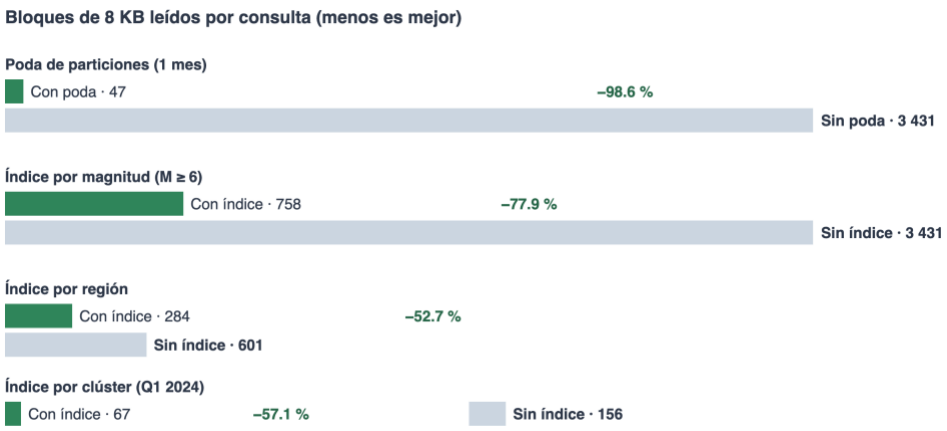


Figura 7. Bloques de 8 KB leídos con y sin cada optimización.

El resultado más notable es la **poda de particiones**: la consulta de un mes lee 47 bloques frente a 3 431 cuando la partición no se aprovecha, una reducción del 98.6 %. Los índices también ayudan: el de magnitud reduce las lecturas un 77.9 % en la búsqueda de sismos fuertes.

Los **bloques leídos son una medida estable**, idéntica en cada repetición. Los tiempos, en cambio, varían con la carga del equipo: en tres reproducciones la poda resultó entre 58 y 83 veces más rápida y el índice entre 4 y 15 veces. Por eso el informe de rendimiento apoya sus conclusiones principalmente en los bloques leídos. Una enseñanza adicional: una tabla con filas muertas duplicó las lecturas en una prueba intermedia, lo que confirma que medir sobre una base mal mantenida distorsiona los resultados.

10. Capa 5: visualización con Grafana

10.1 Grafana como código

Grafana no se configura con clics. La conexión a la base de datos y los dos dashboards se definen en archivos que el contenedor lee al arrancar, de modo que el sistema queda listo sin ningún paso manual y puede destruirse y recrearse en segundos con un resultado idéntico. Los archivos de los dashboards los genera un script, por lo que cualquier cambio se hace en el generador y no en el producto final.

10.2 Dashboard de negocio

Responde a la pregunta "¿qué está pasando con los sismos?". Combina cuatro indicadores clave (total de sismos, magnitud máxima, profundidad real media y tsunamis), un mapa mundial de epicentros coloreado por magnitud, un gráfico que relaciona magnitud y profundidad, una serie semanal con la frecuencia y la energía, y una comparación y auditoría de las 12 zonas sísmicas. Tres filtros permiten explorar los datos: región, zona sísmica y magnitud mínima.

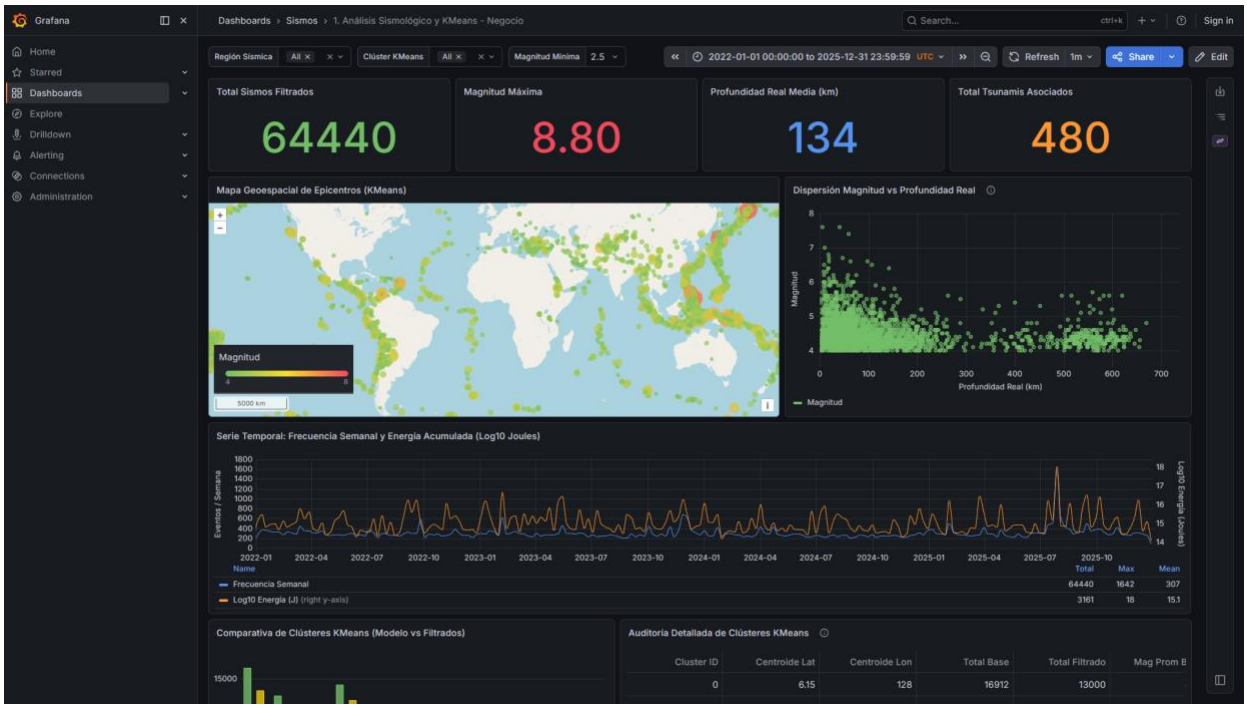


Figura 8. Dashboard de negocio: indicadores, mapa de epicentros, serie temporal y zonas sísmicas.

10.3 Dashboard operacional

Responde a "¿está sano el pipeline?". Muestra cuántos eventos hay en la base, la latencia de NiFi, la duración de Spark, los registros rechazados, el rendimiento a lo largo del tiempo, las tasas de éxito, duplicados y errores por componente, y el detalle de lo descartado y por qué. Se actualiza cada 30 segundos.



Figura 9. Dashboard operacional: estado y calidad de la ingesta y el procesamiento.

10.4 Una lección de diseño

La primera versión de este dashboard sumaba las métricas de todas las ejecuciones y mostraba 564 742 registros procesados, cuando la base tiene 81 044. El error era conceptual: Spark vuelve a leer todo en cada corrida y NiFi informa ventanas móviles de cinco minutos, de modo que sumar sobrecuenta. Los indicadores muestran ahora la última lectura de cada componente, y los eventos descartados se cuentan por la cantidad de eventos que representan y no por el número de filas.

11. Operación y reproducibilidad

El sistema completo se levanta con Docker Compose, que incluye NiFi, PostgreSQL, Spark (bajo demanda) y Grafana. Existen dos caminos para tener datos:

- **Restaurar el respaldo publicado**, la vía rápida, que tarda alrededor de un minuto.
- **Regenerarlos desde las fuentes**: construir los flujos de NiFi, esperar a que baje el histórico (unos seis minutos) y ejecutar Spark. Tarda unos diez minutos y demuestra que el pipeline funciona de principio a fin.

Los flujos de NiFi se construyen mediante scripts que usan su API REST y se exportan como definiciones versionadas. Las capturas de la interfaz que ilustran este informe se generan con un script, de modo que también son reproducibles. El repositorio incluye una carpeta de contexto con los contratos de datos, las decisiones de diseño, las reglas de calidad y una guía de operación, pensada para que otra persona, o una herramienta de inteligencia artificial, pueda continuar el trabajo sin preguntar.

12. Conclusiones

El Monitor Sísmico Global demuestra que una arquitectura de big data completa puede construirse con herramientas abiertas, ser reproducible y mantener la calidad como eje de diseño. Las cinco capas funcionan como un solo sistema: los datos entran validados, se depuran y enriquecen, se almacenan de forma eficiente y se consultan y visualizan con rapidez.

Tres aprendizajes resumen el proyecto. Primero, **los datos reales exigen desconfianza**: una parte muy importante del esfuerzo se dedicó a descubrir valores por defecto, duplicados, correcciones tardías y nombres inconsistentes. Segundo, **idempotencia y trazabilidad** hacen que un pipeline sea confiable: poder repetir una carga sin miedo y saber de dónde vino cada dato cambia la forma de trabajar. Tercero, **integrar y verificar de extremo a extremo vale la pena**: los defectos más importantes aparecieron cuando las dos mitades del proyecto se juntaron.

El resultado es un sistema que puede levantarse en minutos en cualquier equipo, que explica sus decisiones y que deja evidencia de cada afirmación.

Anexo A. Glosario

Término	Significado
Backpressure	Mecanismo de NiFi que frena un paso cuando el siguiente se satura
Rate limiting	Limitación del ritmo de consultas a una API
Idempotencia	Propiedad de una operación que da el mismo resultado si se repite
Partición	División de una tabla en partes, aquí una por mes, para leer solo lo necesario
Poda de particiones	Descarte automático de las particiones que una consulta no necesita
KMeans	Algoritmo que agrupa puntos cercanos; aquí forma las 12 zonas sísmicas
PAGER	Alerta del USGS (verde, amarilla, naranja o roja) sobre el impacto estimado de un sismo
Gutenberg-Richter	Relación que vincula la magnitud de un sismo con su frecuencia y con la energía que libera
Provenance	Registro de NiFi que documenta cada paso por el que pasó un dato
Aprovisionamiento	Configuración automática de un servicio a partir de archivos